

Statistiche sufficienti

La nozione di statistica sufficiente sorge nel momento in cui ci si chiede se sia possibile comprimere un campione di dati osservati senza perdere informazioni sul parametro cercato

Def

Una statistica $T_n(X_1, \dots, X_n)$ si dice sufficiente per il parametro θ se e solo se la distribuzione del campione condizionato a T_n non dipende da θ

Prendendo il caso discreto, denotando la funzione di probabilità di T_n come $q(T_n(x_1, \dots, x_n); \theta)$

è chiamando la funzione di probabilità congiunta del campione

$p(x_1, \dots, x_n; \theta) \rightsquigarrow$ il corrispettivo della densità nel discreto

Allora T è una statistica sufficiente se

$$\frac{p(x_1, \dots, x_n; \theta)}{q(T(x_1, \dots, x_n), \theta)} \text{ non dipende da } \theta$$

Es

Sia $X_1, \dots, X_n \sim \text{iid. Ber}(\theta)$

Sapendo che la loro funzione di prob. congiunta è della forma

$$p(X_1, \dots, X_n; \theta) = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i}$$

Proviamo a vedere se $T_n = \sum_{i=1}^n x_i$ sia una statistica sufficiente

Scriviamo ora la sua funzione di probabilità

$$q(T(x_1, \dots, x_n), \theta) = \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i}$$

Calcoliamo ora

ed è possibile vedere come non dipende da θ

$\Downarrow$

$$\frac{p(x_1, \dots, x_n; \theta)}{q(T(x_1, \dots, x_n), \theta)} = \frac{1}{\binom{n}{\sum_{i=1}^n x_i}}$$

T è una statistica sufficiente

Teo Factorizzazione di Halmos-Savage

Una statistica è sufficiente se e solo se la funzione di probabilità congiunta o densità di $X_1, \dots, X_n$ si factorizza come

$$p(X_1, \dots, X_n; \theta) = g(T(X_1, \dots, X_n); \theta) h(X_1, \dots, X_n)$$

Dove $h(\cdot)$ non dipende da θ

Dim

① Sufficienza $\Rightarrow$ Factorizzazione

Questa implicazione è ovvia, basta prendere

$$g(T(X_1, \dots, X_n); \theta) = q(T(X_1, \dots, X_n); \theta)$$

$h(X_1, \dots, X_n)$ = la legge delle X_i condizionata a T

② Factorizzazione $\Rightarrow$ Sufficienza

Prendiamo il caso discreto e partizioniamo il dominio di $X_1, \dots, X_n$ in classi di equivalenza corrispondenti ai valori della statistica sufficiente

Definiamo allora i sottoinsiemi di $\mathbb{R}^n$ come

$$A_{T(X_1, \dots, X_n)} \in \mathbb{R}^n = \{Y = Y_1, \dots, Y_n : T(Y) = T(X)\}$$

Prendiamo ora il rapporto

$$\frac{p(X_1, \dots, X_n; \theta)}{g(T(X_1, \dots, X_n); \theta)}$$

E dimostriamo come questo non dipende da θ

$$\begin{aligned} \frac{p(X_1, \dots, X_n; \theta)}{g(T(X_1, \dots, X_n); \theta)} &= \frac{g(T(X_1, \dots, X_n); \theta) h(X_1, \dots, X_n)}{\sum_{(Y_1, \dots, Y_n) \in A_{T(X)}} p(Y_1, \dots, Y_n; \theta)} = \frac{g(T(X_1, \dots, X_n); \theta) h(X_1, \dots, X_n)}{\sum_{(Y_1, \dots, Y_n) \in A_{T(X)}} g(T(Y_1, \dots, Y_n); \theta) h(Y_1, \dots, Y_n)} \\ &= \frac{\cancel{g(T(X_1, \dots, X_n); \theta)} h(X_1, \dots, X_n)}{\cancel{g(T(X_1, \dots, X_n); \theta)} \sum_{(Y_1, \dots, Y_n) \in A_{T(X)}} h(Y_1, \dots, Y_n)} = \frac{h(X_1, \dots, X_n)}{\sum_{(Y_1, \dots, Y_n) \in A_{T(X)}} h(Y_1, \dots, Y_n)} \end{aligned}$$

Non dipende

da θ

Es

Sia $X_1, \dots, X_n \sim \text{iid } \mathcal{N}(\mu, 1)$

La loro legge di prob. congiunta e' del tipo

$$p(X_1, \dots, X_n; \mu) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \mu)^2}$$

Consideriamo ora la statistica $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ con legge

$$q(\bar{X}_n; \mu) = \frac{1}{(2\pi)^{1/2}} e^{-\frac{1}{2}(\bar{X}_n - \mu)^2}$$

E' facile vedere che

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X}_n + \bar{X}_n - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2 + \sum_{i=1}^n (\bar{X}_n - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2$$

Quindi possiamo riscrivere

$$p(X_1, \dots, X_n; \mu) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \mu)^2} = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \left(\sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2 \right)} = \frac{1}{(2\pi)^{n/2}} \left[e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \bar{X}_n)^2} e^{-\frac{n}{2} (\bar{X}_n - \mu)^2} \right]$$

q

h

Possiamo notare che la legge di $\bar{X}_n$ $q(\bar{X}_n; \mu)$ e' proprio q

Per questo appunto la statistica $\bar{X}_n$ e' una statistica sufficiente

Questo e' verificabile anche se facciamo

$$\frac{p(X_1, \dots, X_n; \mu)}{q(\bar{X}_n; \mu)} = h = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \bar{X}_n)^2}$$

Che e' indipendente da μ

Teo di Rao-Blackwell

L'idea intuitiva dietro alle statistiche sufficienti e' quella di considerare l'informazione del campione aleatorio conservando quello che e' utile per risalire al "vero" valore del parametro

Sembra quindi intuitivo che gli stimatori efficienti debbano essere costruiti a partire da statistiche sufficienti

Prima di enunciare il teo bisogna ricordare alcune nozioni sul valore medio condizionato

Prendiamo 2 v.a. continue X, Y con densità congiunta

$f_{X,Y}(x,y) \rightarrow$ indica come è distribuita la prob. sul piano (x,y)

Da qui ricaviamo le densità margine

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y) dy$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y) dx$$

Calcoliamo ora i valori attesi di X, Y

$$E[X] = \int_{-\infty}^{+\infty} x f_X(x) dx$$

$$E[Y] = \int_{-\infty}^{+\infty} y f_Y(y) dy$$

La densità condizionata di X dato $Y=y$ è

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

Di conseguenza

$$E[X|Y=y] = \int x f_{X|Y}(x|y) dx \rightarrow \text{è una funzione di } y, \text{ ma essendo fissato il risultato è un numero reale}$$

Ponendo però y con la v.a. Y abbiamo che

$$E[X|Y] = \int x f_{X|Y}(x|Y) dx = \psi(Y) \rightarrow \text{In funzione di } Y$$

$\rightarrow$ indica la migliore stima di X usando l'informazione contenuta in Y

Lemma

Siano X, Y due v.a. di quadrato integrabile definite sullo stesso spazio di probabilità

Allora

$$\text{Var}(X) = E[\text{Var}(X|Y)] + \text{Var}(E[X|Y])$$

Dim

$$\begin{aligned}
 \text{Var}(X) &= E[(X - E[X])^2] = E[(X - E[X|Y] + E[X|Y] - E[X])^2] = \\
 &= E_Y[E[(X - E[X|Y] + E[X|Y] - E[X])^2 | Y]] = \\
 &= E_Y[E[(X - E[X|Y])^2 | Y]] + E_Y[E[(E[X|Y] - E[X])^2 | Y]] \\
 &= E[\text{Var}(X|Y)] + \text{Var}(E[X|Y]) \quad ??? \Rightarrow \text{Da chiedere a Leo perché ha senso}
 \end{aligned}$$

Teo di Rao-Blackwell

Sia $W = W(X_1, \dots, X_n)$ uno stimatore con le seguenti caratteristiche

a) $E[W] = \theta_0 \rightarrow$ non distorto

b) $E[W^2] < \infty \rightarrow$ Var finita

Preso T una statistica sufficiente

Allora è possibile creare un nuovo stimatore W' i.e.

$$W' = E[W|T] \rightarrow \text{non distorto}$$

Con le seguenti caratteristiche

a) $E[W|T] = \theta_0 \rightarrow$ non distorto

b) $\text{Var}(W') \leq \text{Var}(W) \rightarrow$ efficiente

Dim

a) $E[W'] = E[E[W|T]] = E[W] = \theta_0$

b) $\text{Var}[W] = E[\text{Var}(W|T)] + \text{Var}(E[W|T]) \geq \text{Var}(E[W|T]) = \text{Var}(W')$

Oss

In questa dimostrazione non compare minimamente il concetto di statistica sufficiente

Ma in realtà usarlo ci garantisce che il valor medio condizionato non dipenda dal parametro e che quindi $\bar{y}(i)$ sia effettivamente uno stimatore