

Il modello lineare multivariato

Nella pratica è estremamente comune la situazione in cui si cerchi di stimare la relazione esistente fra una particolare variabile, chiamata Y , ed un gruppo di altre v.a. $X_1, \dots, X_K$, dove queste ultime sono considerate esplicative del comportamento della Y .

Si tratta di un caso particolare di un ambito di ricerca spesso indicato come Supervised Learning.

In generale lo studio di relazioni $Y = f(X)$ va anche sotto il nome di Machine Learning.

In questo corso ci si limita a trattare il caso più comune, anche il più semplice, quello in cui si assume che $f(\cdot)$ abbia una forma lineare in un vettore di parametri β .

In particolare, supponiamo che valga la seguente relazione

$$y_i = x_{1i}\beta_1 + x_{2i}\beta_2 + \dots + x_{Ki}\beta_K + \varepsilon_i \quad \forall i=1,2,\dots,n$$


ε_i indica i residui o errori e catturano tutto quello che non è spiegato

In forma matriciale, possiamo scrivere

dalla relazione lineare

$$\bar{Y} = \bar{X}\beta + \bar{\varepsilon}$$

$n \times 1$ $n \times K$ $K \times 1$ $n \times 1$



i puntini in rosso sono gli ε

Dove

$\bar{Y}$ è un vettore $n \times 1$ della forma $\bar{Y} = (y_1, \dots, y_n)^T$

$\bar{X}$ è una matrice $n \times K$ dove l' i -esima colonna è della forma $\bar{X}_i = (x_{1i}, \dots, x_{ni})^T$

$\bar{\varepsilon}$ è un vettore di residui

Bisogna supporre che i residui siano gaussiani

$$\bar{\varepsilon} \sim N(\bar{0}, \sigma^2 I_n)$$

e matrice di Varianza e Covarianza

$$E[\bar{\varepsilon}\bar{\varepsilon}^T] = \Omega$$

Comunemente la prima colonna di $\bar{X}$ viene scelta come colonna di costanti $(1, \dots, 1)$, così ad esempio per $K=2$ abbiamo

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$$

Prima di procedere però, dobbiamo imporre due condizioni per la matrice $\bar{X}$

a) le v.a. $\bar{X}$ sono deterministiche

→ entrambe le condizioni possono essere rimosse

b) il rango della matrice è esattamente $k \sim \text{Rg}(\bar{X}) = k$

→ vengono mantenute per semplicità

Si può notare come queste hp implicino che $k \leq n$

Stimatore ML nel modello lineare multivariato

Proposizione

Lo stimatore ML assume la forma

$$\tilde{\beta}_{MLE} = (\bar{X}^T \bar{X})^{-1} \bar{X}^T \bar{Y}$$

$$\tilde{\sigma}_{MLE}^2 = \frac{1}{n} (\tilde{E}^T \tilde{E})$$

→ il classico errore

Dove $\tilde{E} = \bar{Y} - \tilde{Y} = \bar{Y} - \bar{X} \tilde{\beta}$

Si ha inoltre che

$$\tilde{\beta}_{MLE} \sim \mathcal{N}(\beta, \sigma^2 (\bar{X}^T \bar{X})^{-1})$$

$$n \frac{\tilde{\sigma}_{MLE}^2}{\sigma^2} \xrightarrow{d} \chi^2_{n-k}$$

Dim

→ un vettore di dimensione $k \times 1$

Vogliamo stimare β

Abbiamo innanzitutto che la funzione di verosimiglianza è della forma

$$L(\beta, \sigma^2; \bar{Y}, \bar{X}) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n \epsilon_i^2} = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2} (\bar{Y} - \bar{X}\beta)^T (\bar{Y} - \bar{X}\beta)}$$

→ $\epsilon_i = \langle \epsilon, \epsilon \rangle = \epsilon^T \epsilon, \epsilon = \bar{Y} - \bar{X}\beta$

$$\log L(\beta, \sigma^2; \bar{Y}, \bar{X}) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (\bar{Y} - \bar{X}\beta)^T (\bar{Y} - \bar{X}\beta)$$

→ sono uguali essendo scalari ed uno la trasposto dell'altro

$$\rightarrow = \bar{Y}^T \bar{Y} - \beta^T \bar{X}^T \bar{Y} - \bar{Y}^T \bar{X} \beta + \beta^T \bar{X}^T \bar{X} \beta = \bar{Y}^T \bar{Y} - 2 \bar{Y}^T \bar{X} \beta + \beta^T \bar{X}^T \bar{X} \beta$$

$k \times k$ $k \times 1$ $1 \times k$ $k \times k$

Il calcolo del gradiente ci dà come risultato

$$\nabla_{\beta} \log L(\beta, \sigma^2; \bar{Y}, \bar{X}) = \nabla_{\beta} (\bar{Y}^T \bar{Y} - 2 \bar{Y}^T \bar{X} \beta + \beta^T \bar{X}^T \bar{X} \beta) = 0 - 2 \bar{Y}^T \bar{X} + 2 \bar{X}^T \bar{X} \beta$$

$$\frac{\partial \log L}{\partial \sigma^2} = 0 - \frac{n}{2\sigma^2} + \frac{1}{4\sigma^4} (\bar{Y} - \bar{X}\beta)^T (\bar{Y} - \bar{X}\beta)$$

Quindi abbiamo che

$$\tilde{\beta}_{OLS} = (\bar{X}^T \bar{X})^{-1} (\bar{X}^T \bar{Y})$$

$$\tilde{\sigma}_{OLS}^2 = \frac{1}{n} (\bar{Y} - \bar{X} \tilde{\beta})^T (\bar{Y} - \bar{X} \tilde{\beta}) = \frac{1}{n} (\tilde{\epsilon}^T \tilde{\epsilon})$$

oss

Lo stimatore $\tilde{\beta}_{OLS}$ è noto anche con il nome di OLS (ordinary least squares)

Rapporto con i teoremi di proiezione

Usando gli strumenti di algebra lineare, lo stimatore MLE nel modello lineare multivariato si presta a delle importanti interpretazioni

In particolare si può notare come il valor medio di $\bar{Y}$ dato $\bar{X}$ è dato da $E[\bar{Y}] = \bar{X} \beta$ dove β rimane ignoto

Ma si può definire il valore $\tilde{Y} = X \tilde{\beta}$ come il valore previsto del vettore Y sulla base delle stime $\tilde{\beta}$ e dei regressori X

Analogamente il vettore degli errori $\epsilon = Y - X \beta$ si può stimare come $\tilde{\epsilon} = Y - X \tilde{\beta}$

Notiamo ora che

$$\tilde{Y} = X \tilde{\beta} = X (X^T X)^{-1} (X^T Y) = P_X Y \quad \text{e con} \quad P_X = X (X^T X)^{-1} X^T$$

dove P_X è:

a) Simmetrico $\leadsto P_X = P_X^T$

b) idempotente $\leadsto P_X^2 = X (X^T X)^{-1} X^T X (X^T X)^{-1} X^T = X (X^T X)^{-1} X^T = P_X$

Nello specifico, l'azione della matrice P_X ^{n x n} corrisponde a proiettare il vettore Y sullo spazio vettoriale di dimensione K generato dalle colonne di X

lin. ind. per hp

Span

e quindi $\tilde{Y}$ è spiegato da X

Analogamente abbiamo che

$$\tilde{\epsilon} = Y - X \tilde{\beta} = M_X Y \quad \text{con} \quad M_X = I - P_X = I - X (X^T X)^{-1} X^T$$

dove M_X è:

a) Simmetrico

b) Idempotente

In particolare, l'azione di M_x consiste nel proiettare Y nello spazio ortogonale a quello generato dalle colonne di X

Questo ha alcune conseguenze importanti

Si ha infatti che

$$M_x P_x = P_x M_x = 0$$

matrice $n \times n$ costituita da tutti 0

È qui che stiamo dicendo che $\tilde{E}$ è ciò che non viene spiegato da X

Se lo fosse stato si sarebbe trovato sul "piano" generato da X

Come ulteriore conseguenza notiamo che

$$X^T \tilde{E} = 0$$

ed in particolare il vettore dei residui stimati è ortogonale a qualsiasi vettore che giaccia nello spazio generato dalle colonne di X

Oss

Supponendo che X contenga un termine costante, cioè una colonna della forma

$$e = (1, 1, \dots, 1)^T$$

Allora abbiamo

$$e^T \tilde{E} = 0 \quad \text{ovvero} \quad \sum_{i=1}^n \tilde{E}_i = 0$$

in realtà sarebbe $\sum_{i=1}^n e_i \tilde{E}_i = 0$ ma essendo $e_i = 1$ per costruzione la parte che ci interessa è che $\sum_{i=1}^n \tilde{E}_i = 0$

Quindi la somma dei residui di regressione è sempre nulla se tra i regressori è incluso un termine costante

Lemma

Le matrici P_x, M_x hanno tutti autovalori pari a zero o 1 e rango rispettivamente k e $n-k$

Dim

Poiché le matrici sono reali e simmetriche, si possono diagonalizzare come

$$P_x = Q \Lambda Q^T \quad \text{con} \quad Q Q^T = Q^T Q = I_n \quad \text{e} \quad \Lambda = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & & \\ \vdots & & \ddots & \\ 0 & \dots & 0 & \lambda_n \end{pmatrix}$$

Si ha allora che

P_x è idempotente

$$P_x^2 = Q \Lambda Q^T Q \Lambda Q^T = Q \Lambda^2 Q^T = Q \Lambda Q^T = P_x$$

Da qui segue necessariamente che $\lambda_i = 0$ oppure $\lambda_i = 1$ per $i = 1, \dots, n$

Per quanto riguarda il rango, notiamo che eguaglia il numero di autovalori diversi da 0, quindi nel caso di matrici di proiezioni di Traccia, uguale al numero di quelli che valgono 1

Ricordando che $\text{Tr}(AB) = \text{Tr}(BA)$ possiamo scrivere

$$\text{Tr}(P_x) = \text{Tr}(X(XX^T)^{-1}X^T) = \text{Tr}((X^T X)^{-1}X^T X) = \text{Tr}(I_k) = k = \text{Rg}(P_x)$$

Si può applicare il medesimo ragionamento ad M_x

Distribuzione di $\tilde{\beta}_{ML}$

Ricordando che $Y = X\beta + \varepsilon$

Sostituendo Y nella formula di $\tilde{\beta}_{ML}$ otteniamo

$$\tilde{\beta}_{ML} = (X^T X)^{-1} X^T Y = (X^T X)^{-1} X^T (X\beta + \varepsilon) = \cancel{(X^T X)^{-1} X^T X} \beta + (X^T X)^{-1} X^T \varepsilon = \beta + (X^T X)^{-1} X^T \varepsilon$$

Essendo

β deterministico

$(X^T X)^{-1} X^T$ deterministico

ε un vettore gaussiano

Si può dedurre che anche $\tilde{\beta}_{ML}$ sia un vettore gaussiano in quanto $\tilde{\beta}_{ML}$ è combinazione lineare di gaussiane

$$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_k)$$

Di conseguenza otteniamo che

$$E[\tilde{\beta}_{ML}] = E[\beta + (X^T X)^{-1} X^T \varepsilon] = E[\beta] + E[(X^T X)^{-1} X^T \varepsilon] = \beta + (X^T X)^{-1} X^T E[\varepsilon] = \beta$$

$$\text{Var}(\tilde{\beta}_{ML}) = E[(\tilde{\beta}_{ML} - \beta)(\tilde{\beta}_{ML} - \beta)^T] = E[(\beta + (X^T X)^{-1} X^T \varepsilon - \beta)(\beta + (X^T X)^{-1} X^T \varepsilon - \beta)^T] =$$

$$= E[(X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1}] = (X^T X)^{-1} X^T E[\varepsilon \varepsilon^T] X (X^T X)^{-1}$$

$$= (X^T X)^{-1} X^T \underbrace{E[\varepsilon \varepsilon^T]}_{\substack{\varepsilon \sim \mathcal{N}(0, \sigma^2 I_k) \\ \text{scalare}}} X (X^T X)^{-1} = (X^T X)^{-1} X^T \sigma^2 I_k X (X^T X)^{-1} = (X^T X)^{-1} \sigma^2 I_k X (X^T X)^{-1}$$

$$= \cancel{(X^T X)^T} X^T X (X^T X)^T \sigma^2$$

Quindi abbiamo verificato che

$$\tilde{\beta} \sim \mathcal{N}(\beta, \sigma^2 (X^T X)^{-1})$$

Distribuzione di $\tilde{\sigma}^2$

Ricordando che

$$\tilde{\sigma}^2 = \frac{\tilde{E}^T \tilde{E}}{n} = \frac{(Y - X\tilde{\beta})^T (Y - X\tilde{\beta})}{n}$$

Capiamo ora come si distribuiscono $\tilde{E}$

Riscriviamo $\tilde{E}$ come

$$\tilde{E} = Y - X\tilde{\beta} = Y - X \underbrace{(X^T X)^{-1} X^T}_{P_X} Y = (\tilde{I}_d - P_X) Y$$

$(\tilde{I}_d - P_X)$ è ortogonale ad X

Ora sapendo che $Y = X\beta + \varepsilon$ possiamo riscrivere $\tilde{E}$ come

$X\beta \in \text{Col}(X)$ allora $(\tilde{I}_d - P_X)X\beta = 0$

$$\tilde{E} = (\tilde{I}_d - P_X)Y = (\tilde{I}_d - P_X)(X\beta + \varepsilon) = (\tilde{I}_d - P_X)X\beta + (\tilde{I}_d - P_X)\varepsilon = (\tilde{I}_d - P_X)\varepsilon$$

Per quanto riguarda il valore atteso e la varianza abbiamo che

$$\mathbb{E}[\tilde{E}] = \mathbb{E}[(\tilde{I}_d - P_X)\varepsilon] = (\tilde{I}_d - P_X)\mathbb{E}[\varepsilon] = 0$$

deterministico

$$\text{Var}(\tilde{E}) = \text{Var}((\tilde{I}_d - P_X)\varepsilon) = (\tilde{I}_d - P_X) \text{Var}(\varepsilon) (\tilde{I}_d - P_X)^T = (\tilde{I}_d - P_X) \text{Var}(\varepsilon) = (\tilde{I}_d - P_X) \tilde{I}_d \sigma^2$$

$\tilde{I}_d - P_X$ è idempotente

Sapendo che gli $\varepsilon \sim \mathcal{N}(0, \sigma^2 \tilde{I}_d)$ allora possiamo notare che $\tilde{E} = (\tilde{I}_d - P_X)\varepsilon$ non è altro che una combinazione lineare di Gaussiane quindi,

$$\tilde{E} \sim \mathcal{N}(0, \sigma^2 (\tilde{I}_d - P_X))$$

Ora abbiamo tutti gli strumenti per dimostrare il seguente lemma

Lemma

Lo stimatore $\tilde{\sigma}_{n-k}^2 = \tilde{E}^T \tilde{E} = (Y - X\tilde{\beta})(Y - X\tilde{\beta})^T$ si distribuisce come

$$\tilde{\sigma}_{n-k}^2 \sim \sigma^2 \chi_{n-k}^2$$

Per semplicità non viene considerato lo n al denominatore

Dim

Scriviamo innanzi tutto

$$M_x = I_d - P_x$$

Quindi possiamo scrivere $\tilde{E}$ come

$$\tilde{E} = (I_d - P_x)E = M_x E$$

Allora

$$\tilde{E}^T \tilde{E} = (M_x E)^T (M_x E) = E^T M_x^T M_x E = E^T M_x E$$

M_x simmetrico e idempotente

Ricordando che M_x è diagonalizzabile

$$M_x = Q \Lambda Q^T$$

dove Λ ha $n-k$ elementi pari ad 1 sulla diag. e tutti gli altri pari a 0
otteniamo che

$$E^T M_x E = E^T Q \Lambda Q^T E$$

$Q^T E \sim N(0, 0, Q^T I_d \sigma^2 Q^T = I_d \sigma^2)$

Definiamo ora $u = Q^T E$ e, poiché $E \sim N(0, \sigma^2 I_d)$, $u \sim N(0, \sigma^2 I_d)$ e quindi normalizzando
otteniamo che

$$u_i = \sigma Z_i \text{ con } Z_i \sim N(0, 1)$$

Concludendo ora abbiamo che

$$u^T \Lambda u = \sum_{i=1}^{n-k} u_i^2 = \sigma^2 \sum_{i=1}^{n-k} Z_i^2 \sim \sigma^2 \chi_{n-k}^2$$

rank di Λ

Lemma di Cochran

Matrice di varianza e covarianza

rango pieno

Sia $W \sim \mathcal{N}(W_0, \Sigma_W)$ un certo vettore gaussiano con $\text{rg}(\Sigma_W) = p$

Allora vale che

$$(W - W_0)^T \Sigma_W^{-1} (W - W_0) \sim \chi_p^2$$

Dim

Riscriviamo la relazione come

$$\begin{aligned} (W - W_0)^T \Sigma_W^{-1} (W - W_0) &= (W - W_0)^T (\Sigma_W^{-1/2})^T (\Sigma_W^{-1/2}) (W - W_0) = \\ &= \left(\Sigma_W^{-1/2} (W - W_0) \right)^T \left(\Sigma_W^{-1/2} (W - W_0) \right) \end{aligned}$$

Per terminare la dimostrazione basta dimostrare che

$$Z = \Sigma_W^{-1/2} (W - W_0) \sim \mathcal{N}(0, I_d)$$

Calcoliamo ora $E[Z]$

$$W \sim \mathcal{N}(W_0, \Sigma_W)$$

$$E[Z] = E\left[\Sigma_W^{-1/2} (W - W_0)\right] = \Sigma_W^{-1/2} (E[W] - E[W_0]) = \Sigma_W^{-1/2} (W_0 - W_0) = 0$$

Calcoliamo invece ora $\text{Var}(Z)$

$$\text{Var}(Z) = \text{Var}\left(\Sigma_W^{-1/2} (W - W_0)\right) = \left(\Sigma_W^{-1/2}\right)^T \text{Var}(W - W_0) \Sigma_W^{-1/2} = \Sigma_W^{-1/2} \Sigma_W \Sigma_W^{-1/2}$$

Sapendo che $\Sigma_W^{-1/2}$ e Σ_W sono diag possiamo scrivere

Q e Q^T sono ortogonali $\leadsto Q Q^T = I_d$

$$\Sigma_W^{-1/2} \Sigma_W \Sigma_W^{-1/2} = Q \Lambda^{-1/2} Q^T Q \Lambda Q^T Q \Lambda^{-1/2} Q^T = Q \Lambda^{-1/2} \Lambda \Lambda^{-1/2} Q^T = Q I_d Q^T = I_d$$

Sapendo che $Z \sim \mathcal{N}(0, I_d)$ è facile vedere come

$$\left(\Sigma_W^{-1/2} (W - W_0) \right)^T \left(\Sigma_W^{-1/2} (W - W_0) \right) = Z^T Z = \sum_{i=1}^p z_i^2 \sim \chi_p^2$$