

## 13 Statistiche sufficienti

Una domanda naturale che possiamo porci, specialmente in un momento in cui masse enormi di dati sono a disposizione, è la seguente: posso comprimere un campione di dati osservati senza perdere informazione sul parametro che mi interessa? Questa domanda ci porta alla nozione di statistiche sufficienti.

### Spiegazione Semplice

#### Cos'è una "Statistica Sufficiente"?

L'idea è molto intuitiva: una statistica (come la media campionaria,  $\bar{X}$ ) è "sufficiente" se **contiene tutta l'informazione** sul parametro  $\theta$  (come la media vera,  $\mu$ ) che era contenuta nell'intero campione originale  $(X_1, \dots, X_n)$ .

È un metodo di "compressione dati" perfetto: ci permette di buttare via l'intero dataset (che possono essere Terabyte di dati) e tenere solo un numero (o un piccolo set di numeri), con la garanzia di non aver perso *nessuna informazione* utile per stimare il nostro parametro.

Ad esempio, se voglio stimare la media  $\mu$  di una popolazione Gaussiana, non mi serve sapere i 1000 valori individuali; mi "è sufficiente" conoscere la loro somma  $\sum X_i$  (o la loro media  $\bar{X}$ ).

**Definition 116** (Statistiche sufficienti). *Una statistica  $T_n = T(X_1, \dots, X_n)$  si dice sufficiente per il parametro  $\theta$  se la distribuzione del campione condizionata a  $T_n$  non dipende da  $\theta$ . In altre parole, la legge  $p(X_1, \dots, X_n | T_n)$  non dipende dal parametro. In questa sezione, supponiamo sempre per semplicità di avere a che fare con variabili aleatorie discrete; in questo ambito, è immediato verificare che conoscendo solo la statistica sufficiente possiamo generare un nuovo campione uguale in distribuzione all'originale. Abbiamo infatti, per qualsiasi scelta di valori  $(x_1, x_2, \dots, x_n)$*

$$\begin{aligned} & Pr(X_1 = x_1, \dots, X_n = x_n) \\ &= Pr(X_1 = x_1, \dots, X_n = x_n \cap T(X_1, \dots, X_n) = T(x_1, \dots, x_n)) \\ &= Pr(X_1 = x_1, \dots, X_n = x_n | T(X_1, \dots, X_n) = T(x_1, \dots, x_n)) Pr(T(X_1, \dots, X_n) = T(x_1, \dots, x_n)) \\ &= Pr(Y_1 = x_1, \dots, Y_n = x_n | T(Y_1, \dots, Y_n) = T(x_1, \dots, x_n)) Pr(T(X_1, \dots, X_n) = T(x_1, \dots, x_n)) \\ &= Pr(Y_1 = x_1, \dots, Y_n = x_n) \end{aligned}$$

dove le  $Y_i$  sono generate dalla distribuzione condizionata delle  $X_i$  a  $T$ ; poichè l'uguaglianza vale per tutte le scelte di  $(x_1, \dots, x_n)$  abbiamo quindi dimostrato che

$$(Y_1, \dots, Y_n) \underline{d} (X_1, \dots, X_n).$$

Si noti che nella dimostrazione (primo passaggio) abbiamo anche utilizzato il fatto che l'evento  $X_1 = x_1, \dots, X_n = x_n$  è contenuto nell'evento  $T(X_1, \dots, X_n) = T(x_1, \dots, x_n)$ , e pertanto la probabilità della loro intersezione è uguale alla probabilità di  $X_1 = x_1, \dots, X_n = x_n$ . Più in generale, denotiamo  $q(T(X_1, \dots, X_n); \theta)$  la funzione di probabilità della statistica sufficiente  $T$ ; dalla definizione di probabilità condizionata è immediato verificare che  $T$  è sufficiente se e solo se  $p(X_1, \dots, X_n; \theta) / q(T(X_1, \dots, X_n); \theta)$  non dipende da  $\theta$ .

### Spiegazione Semplice

#### Cosa significa la Definizione Formale?

La definizione  $p(X_1, \dots, X_n | T_n)$  "non dipende da  $\theta$ " è un modo molto tecnico per dire: "Una volta che ti ho detto il valore della statistica  $T_n$  (es. la somma è 7), il campione originale  $(X_1, \dots, X_n)$  non contiene più nessuna informazione *aggiuntiva* sul parametro  $\theta$ ."

Tutta l'informazione su  $\theta$  è stata "aspirata" e si trova ora in  $T_n$ . Sapere l'ordine esatto in cui sono usciti i dati (es. T-C-T-C... vs T-T-C-C...) non ci aiuta in alcun modo a stimare  $\theta$ , una volta che sappiamo già che la somma è  $T_n$ .

**Example 117.** Si consideri un campione IID di variabili Bernoulliane  $X_i \sim \text{Ber}(\theta)$ . La loro legge congiunta è data da

$$p(X_1, \dots, X_n; \theta) = \theta^{\sum_{i=1}^n X_i} (1 - \theta)^{n - \sum_{i=1}^n X_i}.$$

Verifichiamo che  $T_n := \sum_{i=1}^n X_i$  sia una statistica sufficiente; la sua funzione di probabilità è una binomiale, data quindi da

$$q(T_n(X_1, \dots, X_n); \theta) = \binom{n}{\sum_{i=1}^n X_i} \theta^{\sum_{i=1}^n X_i} (1 - \theta)^{n - \sum_{i=1}^n X_i}$$

e quindi

$$\frac{p(X_1, \dots, X_n; \theta)}{q(T_n(X_1, \dots, X_n); \theta)} = \frac{1}{\binom{n}{\sum_{i=1}^n X_i}}$$

che è indipendente da  $\theta$ .

### Spiegazione Semplice

#### Esempio 1: Lancio di Monete (Bernoulli)

- **Campione**  $(X_1, \dots, X_n)$ : L'elenco esatto dei risultati dei lanci (es.  $X_1 = 1, X_2 = 0, X_3 = 1, \dots$ ).
- **Parametro**  $(\theta)$ : La probabilità (ignota) che esca Testa ( $p$ ).
- **Statistica**  $(T_n)$ : La somma  $\sum X_i$ , cioè il numero totale di Teste (es.  $k = 7$ ).

Per stimare  $\theta$ , ci interessa l'ordine in cui sono uscite Teste e Croci? No. L'unica cosa che ci serve è il *numero totale* di Teste (la somma  $T_n$ ).

La formula  $p(X|T) = 1/\binom{n}{k}$  (che non dipende da  $\theta$ ) lo dimostra: una volta che ti ho detto che "su  $n$  lanci,  $k$  sono Teste", la probabilità di una specifica sequenza (es. T-T-C) è 1 diviso il numero di tutte le sequenze possibili con  $k$  Teste. Il parametro  $\theta$  è sparito.

**Example 118.** Si consideri un campione IID di variabili Gaussiane  $X_i \sim N(\theta, 1)$ . La loro legge congiunta è data da

$$p(X_1, \dots, X_n; \mu) = \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} \sum_{i=1}^n (X_i - \mu)^2\right);$$

consideriamo ora la statistica  $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$  con legge  $N(\mu, \frac{1}{n})$  cioè

$$q(\bar{X}_n; \mu) = \frac{\sqrt{n}}{(2\pi)^{1/2}} \exp\left(-\frac{n}{2} (\bar{X}_n - \mu)^2\right).$$

E' facile verificare che

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X}_n + \bar{X}_n - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2$$

da cui

$$\begin{aligned} \frac{p(X_1, \dots, X_n; \mu)}{q(\bar{X}_n; \mu)} &= \text{Const} \times \frac{\exp(-\frac{1}{2} \sum_{i=1}^n (X_i - \mu)^2)}{\exp(-\frac{n}{2} (\bar{X}_n - \mu)^2)} \\ &= \text{Const} \times \exp\left(-\frac{1}{2} \sum_{i=1}^n (X_i - \bar{X}_n)^2\right), \end{aligned}$$

e la dimostrazione della sufficienza è completata.

### Spiegazione Semplice

#### Esempio 2: Media Gaussiana

Allo stesso modo, se abbiamo  $n$  misurazioni da una distribuzione Gaussiana  $N(\mu, 1)$  e vogliamo stimare la media vera  $\mu$ .

La media campionaria  $\bar{X}_n$  (o la somma, sono equivalenti) è una statistica sufficiente.

L'algebra (che scompone  $\sum (X_i - \mu)^2$  in  $\sum (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2$ ) mostra che il rapporto  $p(X|\bar{X})$  dipende solo da  $\sum (X_i - \bar{X}_n)^2$ , che è la varianza campionaria. Questo termine non contiene  $\mu$  (il parametro  $\theta$ ).

Ancora una volta,  $\bar{X}_n$  ha "catturato" tutta l'informazione su  $\mu$  contenuta nel campione.

A metà del ventesimo secolo Halmos e Savage hanno dato una caratterizzazione della sufficienza leggermente più generale, come segue.

**Theorem 119** (Criterio di Fattorizzazione di Halmos e Savage). *Una statistica è sufficiente se e solo se la funzione di probabilità (o di densità) di  $X_1, \dots, X_n$  si fattorizza come*

$$p(X_1, \dots, X_n; \theta) = g(T(X_1, \dots, X_n); \theta)h(X_1, \dots, X_n)$$

dove la funzione  $h(\cdot)$  non dipende da  $\theta$ .

### Spiegazione Semplice

#### Un "Test" Pratico per la Sufficienza

La definizione formale (Def. 116) che usa la probabilità condizionata  $p(X|T)$  è un incubo da usare per le dimostrazioni.

Questo teorema (il Criterio di Fattorizzazione) ci dà un "test" molto più semplice. Per dimostrare che  $T$  è sufficiente, ti basta fare un po' di algebra:

1. Prendi la funzione di verosimiglianza  $p(X_1, \dots, X_n; \theta)$ .
2. Prova a "spezzarla" (fattorizzarla) in due pezzi moltiplicati tra loro:
  - **Pezzo  $g$ :** Una funzione  $g$  che dipende dal parametro  $\theta$ , ma che "vede" i dati  $X$  solo attraverso la statistica  $T(X)$ .
  - **Pezzo  $h$ :** Una funzione  $h$  che può dipendere da tutti i dati  $X$  in modo complicato, ma non deve contenere il parametro  $\theta$ .

Se riesci a fare questa separazione, hai dimostrato che  $T(X)$  è sufficiente.

*Dimostrazione.* L'implicazione sufficienza  $\Rightarrow$  fattorizzazione è ovvia: basta prendere per  $g(T; \theta) = q(T; \theta)$  (la legge di  $q$ ) e  $h$  la legge delle  $X_i$  condizionata a  $T$ , che sappiamo essere indipendente da  $\theta$ . L'interesse del Teorema è quindi nella seconda parte, cioè nel caso in cui la fattorizzazione non corrisponda necessariamente alla coppia legge di  $T$ / legge di  $X_1, \dots, X_n$  condizionata a  $T$ . Come sempre in questa sezione ci limitiamo al caso discreto, e partizioniamo il dominio di  $X_1, \dots, X_n$  in classi di equivalenza corrispondenti ai valori della statistica sufficiente; definiamo cioè i sottoinsiemi di  $\mathbb{R}^n$

$$A_{T(x_1, \dots, x_n)} = \{(x'_1, \dots, x'_n) : T(x'_1, \dots, x'_n) = T(x_1, \dots, x_n)\}.$$

Andiamo a calcolare, per  $x_1, \dots, x_n$  qualsiasi ma fissati

$$\begin{aligned} \frac{p(x_1, \dots, x_n; \theta)}{q(T(x_1, \dots, x_n); \theta)} &= \frac{g(T(x_1, \dots, x_n; \theta))h(x_1, \dots, x_n)}{q(T(x_1, \dots, x_n); \theta)} \\ &= \frac{g(T(x_1, \dots, x_n; \theta))h(x_1, \dots, x_n)}{\sum_{(x'_1, \dots, x'_n) \in A_{T(x_1, \dots, x_n)}} p(x'_1, \dots, x'_n; \theta)} \\ &= \frac{g(T(x_1, \dots, x_n; \theta))h(x_1, \dots, x_n)}{\sum_{(x'_1, \dots, x'_n) \in A_{T(x_1, \dots, x_n)}} g(T(x_1, \dots, x_n; \theta))h(x'_1, \dots, x'_n)} \\ &= \frac{h(x_1, \dots, x_n)}{\sum_{(x'_1, \dots, x'_n) \in A_{T(x_1, \dots, x_n)}} h(x'_1, \dots, x'_n)}; \end{aligned}$$

l'ultima frazione non dipende da  $\theta$ , il che è sufficiente a concludere la dimostrazione della sufficienza.  $\square$

### 13.1 Il Teorema di Rao-Blackwell

L'idea intuitiva dietro le statistiche sufficienti è quella di condensare l'informazione del campione aleatorio conservando quello che è utile per risalire al valore "vero" del parametro. Sembra quindi intuitivo che gli stimatori efficienti debbano essere costruiti solo a partire da statistiche sufficienti. Questa idea è resa rigorosa dal teorema di Rao-Blackwell; prima di enunciarlo, dobbiamo ricordare alcune nozioni sul valor medio condizionato, restringendoci solamente al caso discreto. Siano  $X, Y$  valori aleatorie discrete con momento secondo finito e funzione di probabilità congiunta  $P_{XY}(x, y)$ ; la densità di  $X$  condizionata a  $Y = y$  è data da

$$p_{X|Y}(x|y) = \begin{cases} \frac{p_{XY}(x, y)}{p_Y(y)}, & \text{se } p_Y(y) > 0 \\ 0 & \text{altrimenti} \end{cases}$$

(Nota: il testo originale riporta  $p_X(x)$  al denominatore e  $p_{X|Y}(x, y)$  a sinistra, ma  $p_Y(y)$  e  $p_{X|Y}(x|y)$  sono corretti)

ed il valor medio condizionato a  $Y = y$  naturalmente

$$E[X|Y = y] = \sum_{x \in \text{Dom}(X)} x p_{X|Y}(x|y)$$

(Nota: il testo originale presenta una formula parziale e diversa  $E[X|Y = y] = \sum x p_{XY}(x, y)/p_Y(y)$ )

Se evitiamo di fissare il valore della variabile aleatoria  $Y$ , avremo ora una nuova variabile aleatoria (funzione di  $Y$ ) della forma  $\psi(Y) = E[X|Y]$ , che ad ogni valore di  $Y$  associa il valore del valor medio condizionato corrispondente a quel valore

$$E[X|Y] = \sum_{x \in \text{Dom}(X)} x \frac{p_{XY}(x, Y)}{p_Y(Y)} = \sum_{x \in \text{Dom}(X)} x p_{X|Y}(x|Y);$$

in altre parole,  $\psi(Y)$  assume il valore  $\psi(y) = E[X|Y = y]$  con probabilità  $p_Y(y)$  (la legge marginale di  $Y$ ). E' immediato verificare che (la cosiddetta legge del valor medio iterato)

$$E[E[X|Y]] = E[X];$$

infatti

$$\begin{aligned} E[E[X|Y]] &= \sum_y E[X|Y = y] p_Y(y) = \sum_y \sum_{x \in \text{Dom}(X)} x \frac{p_{XY}(x, y)}{p_Y(y)} p_Y(y) \\ &= \sum_{x \in \text{Dom}(X)} x \sum_y p_{XY}(x, y) \\ &= \sum_{x \in \text{Dom}(X)} x p_X(x) = E[X]. \end{aligned}$$

Allo stesso modo possiamo definire la variabile aleatoria (funzione di  $Y$ )

$$\text{Var}[X|Y] = \sum_{x \in \text{Dom}(X)} (x - E[X|Y])^2 p_{X|Y}(x|Y),$$

che corrisponde alla varianza condizionata di  $X$ , in funzione del valore aleatorio di  $Y$ . Vale il seguente risultato.

**Lemma 120.** *Siano  $X, Y$  variabili aleatorie di quadrato integrabile definite sullo stesso spazio di probabilità. Abbiamo*

$$\text{Var}[X] = E[\text{Var}[X|Y]] + \text{Var}[E[X|Y]].$$

#### Spiegazione Semplice

##### Scomposizione della Varianza

Questo lemma è un risultato fondamentale della probabilità, noto come **Legge della Varianza Totale**. Dice che la variabilità (Varianza) totale di una variabile  $X$  può essere scomposta in due parti:

1.  $E[Var[X|Y]]$ : La **varianza interna media**. È la variabilità *residua* di  $X$  che *non* è spiegata da  $Y$ . (Quanto "balla" ancora  $X$  dopo che  $Y$  è noto, in media).
2.  $Var[E[X|Y]]$ : La **varianza esterna**. È la variabilità di  $X$  che è *spiegata* da  $Y$ . (Quanto "balla" la media di  $X$  al variare di  $Y$ ).

Varianza Totale = Varianza non Spiegata + Varianza Spiegata.

*Dimostrazione.* Abbiamo che

$$\begin{aligned} Var[X] &= E[(X - E[X])^2] \\ &= E[(X - E[X|Y] + E[X|Y] - E[X])^2] \\ &= E[(X - E[X|Y])^2] + E[(E[X|Y] - E[X])^2] \\ &\quad + 2E[(X - E[X|Y])(E[X|Y] - E[X])]. \end{aligned}$$

Ora per definizione abbiamo

$$E[(E[X|Y] - E[X])^2] = E_Y[(E[X|Y] - E[X])^2] = Var[E[X|Y]];$$

inoltre

$$\begin{aligned} E[(X - E[X|Y])(E[X|Y] - E[X])] &= E_Y[E[(X - E[X|Y])(E[X|Y] - E[X])|Y]] \\ &= E_Y[(E[X|Y] - E[X])E[(X - E[X|Y])|Y]] \\ &= 0, \end{aligned}$$

perché  $E[(X - E[X|Y])|Y] = 0$ . Infine

$$E[(X - E[X|Y])^2] = E[E[(X - E[X|Y])^2|Y]] = E[Var[X|Y]],$$

e il Lemma è dimostrato.  $\square$

Possiamo finalmente arrivare al risultato principale, che ci garantisce che condizionando uno stimatore non distorto su una statistica sufficiente se ne ottiene un altro ancora non distorto e con varianza non maggiore.

**Theorem 121** (Rao-Blackwell). *Sia  $W_n = W_n(X_1, \dots, X_n)$  uno stimatore non distorto e con varianza finita del parametro  $\theta$ , e sia  $T_n = T(X_1, \dots, X_n)$  una statistica sufficiente per  $\theta$ . Definiamo  $\psi(T) = E[W_n|T]$ ; allora abbiamo*

$$E[\psi(T)] = \theta \text{ e } Var[\psi(T)] \leq Var[W_n]$$

### Spiegazione Semplice

#### Perché le Statistiche Sufficienti sono così importanti?

Questo teorema è la risposta. Ci fornisce una **ricetta per migliorare uno stimatore**.

1. **Partenza:** Hai uno stimatore  $W_n$  che è "onesto" (non distorto,  $E[W_n] = \theta$ ) ma magari non molto "preciso" (ha una varianza  $Var[W_n]$  alta).
2. **Ingrediente Chiave:** Trovi una statistica *sufficiente*  $T_n$  (che "aspira" tutta l'informazione su  $\theta$  dal campione).
3. **Ricetta:** Crei un nuovo stimatore  $\psi(T)$  calcolando la media del tuo vecchio stimatore  $W_n$  dato  $T_n$ . (In pratica,  $\psi(T) = E[W_n|T_n]$ ).

**Risultato:** Il tuo nuovo stimatore  $\psi(T)$  è **sempre migliore** (o al peggio uguale) del vecchio  $W_n$ :

- È ancora "onesto" (non distorto):  $E[\psi(T)] = \theta$ .
- È più "preciso" (ha una varianza minore):  $Var[\psi(T)] \leq Var[W_n]$ .

Questo teorema ci dice che se stiamo cercando lo stimatore "migliore" (con varianza minima), dobbiamo cercarlo *solo* tra le funzioni di statistiche sufficienti.

*Dimostrazione.* La dimostrazione è una applicazione immediata dei risultati precedenti sul valor medio condizionato. In particolare

$$\begin{aligned} E[\psi(T)] &= E[E[W_n|T]] = E[W_n] = \theta, \\ \text{Var}[W_n] &= E[\text{Var}[W_n|T]] + \text{Var}[E[W_n|T]] \\ &\geq \text{Var}[E[W_n|T]] = \text{Var}[\psi(T)]. \end{aligned}$$

□

### Spiegazione Semplice

#### La Dimostrazione (spiegata dal Lemma 120)

La dimostrazione è incredibilmente elegante e usa direttamente il Lemma 120 (Legge della Varianza Totale):

$$\text{Var}[W_n] = E[\text{Var}[W_n|T]] + \text{Var}[E[W_n|T]]$$

Guardiamo i due pezzi:

- $\text{Var}[E[W_n|T]]$ : Questa è la varianza del nostro *nuovo* stimatore  $\psi(T)$ .
- $E[\text{Var}[W_n|T]]$ : Questa è la "varianza interna media". Poiché una varianza non può mai essere negativa, questo termine è sempre  $\geq 0$ .

Quindi, la formula ci dice:  $\text{Var}(\text{Vecchio Stimatore}) = (\text{Termine} \geq 0) + \text{Var}(\text{Nuovo Stimatore})$ . Questo implica matematicamente che  $\text{Var}(\text{Vecchio Stimatore}) \geq \text{Var}(\text{Nuovo Stimatore})$ .

**Remark 122.** Dove abbiamo usato nella dimostrazione precedente la sufficienza? Apparentemente non gioca alcun ruolo, ma in realtà ci garantisce che il valor medio condizionato non dipenda dal parametro, e quindi che  $\psi(T)$  sia effettivamente uno stimatore. Ad esempio consideriamo un campione di sole due osservazioni  $X_1, X_2$  Gaussiane indipendenti con valor medio  $\mu$  e varianza 1, e consideriamo lo stimatore  $\bar{X}_2 = \frac{1}{2}(X_1 + X_2)$ . Consideriamo

$$\psi(X_1) := E[\bar{X}_2|X_1] = \frac{X_1 + \mu}{2}$$

Questa variabile aleatoria ha valor medio  $\mu$  e varianza  $\frac{1}{4} < \text{Var}(\bar{X}_2) = \frac{1}{2}$ ; non si tratta però di uno stimatore, perchè il suo valore non può essere determinato senza conoscere il valore del parametro  $\mu$ .

### Spiegazione Semplice

#### Perché la "Sufficienza" è la chiave? (Un punto sottile)

Questo remark è cruciale. La dimostrazione  $\text{Var}(W_n) \geq \text{Var}(\psi(T))$  funziona sempre, ma *non serve a nulla* se  $\psi(T) = E[W_n|T]$  non è un vero stimatore.

Uno "stimatore" (Def. 80) deve essere una formula calcolabile *solo* dai dati  $(X_1, \dots, X_n)$ , senza conoscere il parametro  $\theta$  (altrimenti che stima è?).

- **L'esempio fallimentare:** Il testo usa  $T = X_1$  (che *non* è sufficiente per  $\mu$ ). Se proviamo ad applicare Rao-Blackwell, il "nuovo stimatore" è  $\psi(X_1) = E[\bar{X}_2|X_1] = \frac{X_1 + \mu}{2}$ . Questa formula è *inutilizzabile*: per calcolarla serve  $\mu$ , che è proprio il valore che non conosciamo!
- **Perché la sufficienza salva tutto:** Se  $T$  è *sufficiente* (Def. 116), la distribuzione  $p(X|T)$  *non dipende da*  $\theta$ . Di conseguenza, anche la media  $E[W_n|T]$  (che si calcola usando  $p(X|T)$ ) non dipenderà da  $\theta$ . Sarà una vera formula calcolabile solo dai dati, e quindi un vero stimatore.