

Quanti siti ci sono nel Web?

Tra la fine del 2025 e l'inizio del 2026, Internet ospita 1,34 miliardi di siti web a livello globale, rispetto a soli 17 milioni nel 2000: un aumento di 75 volte in circa 25 anni.

Approssimativamente il 15% viene attivamente mantenuto e aggiornato, il che significa che circa 201 milioni di siti web sono attivi e fungono da nodi essenziali.

Il numero di siti web varia quotidianamente poiché ne vengono creati di nuovi e quelli vecchi diventano inattivi.

In particolare, il traguardo di 1 miliardo di siti web è stato raggiunto per la prima volta nel settembre 2014.

Vengono creati circa 1,25 milioni di nuovi siti web ogni giorno, spinti dalla costante crescita nell'espansione dell'e-commerce, dalla monetizzazione dei contenuti e dalla trasformazione digitale in tutti i settori.

Information Retrieval

L'information Retrieval (IR) è la **ricerca di materiale** (di solito documenti) di natura **non strutturata** (di solito testo) che soddisfa un **bisogno informativo** all'interno di **grandi collezioni** (di soliti memorizzate su computer).

Oggigiorno pensiamo spesso prima alla **ricerca sul web**, ma ci sono molti altri casi:

- Ricerca nelle e-mail,
- Ricerca sul proprio computer portatile,
- Basi di conoscenza aziendali,
- Reperimento di informazioni legali.

Inizialmente (fino a qualche anno fa) avevamo più dati **non strutturati** che **strutturati** (80-20). Però in genere i soldi giravano più su quelli strutturati.

Adesso però anche il mercato sui dati non strutturati è cresciuto molto, superando quello sui dati strutturati.

Assunti di base dell'Information Retrieval

- **Collezione:** Un insieme di documenti
 - Assumiamo per il momento che sia una collezione statica.
- **Obiettivo:** Recuperare documenti con informazioni che siano **rilevanti** per il **bisogno informativo** dell'utente e che lo aiutino a completare un **compito** (o un'attività).

IR vs DB

- **DB** accesso ai dati in base a dei **metadati** che descrivono un documento.
- **IR** consentono di trovare un documento in base al suo contenuto.

IR	DBMS
Semantica libera	Semantica rigorosa e precisa
Ricerca in base al contenuto	SQL (linguaggio rigoroso)
Dati non strutturati (documento)	Dati rigorosamente strutturati
Principalmente in lettura. Più richiesto di lettura che scrittura (leggo più tweet di quanti ne scrivo)	Più o meno lettura e lettura equivalenti
Si richiedono i primi k elementi, ordinati per qualità.	Si richiedono tutti i possibili risultati.

Modello "Bag of Words" nell'IR

- **Tipico modello dei dati nell'IR:**
 - Ogni documento è semplicemente un bag (multinsieme) di parole ("termini" o "words").
 - Il bag modella un documento proprio come un BBox (Bounding Box) modella un oggetto spaziale.
- ****Dettaglio 1: "Stop Words" (Parole non significative)**
 - Alcune parole sono considerate irrilevanti e non vengono inserite nel bag.
 - es., l'articolo "the".
 - es., i tag HTML come $< H1 >$
- **Dettaglio 2: "Stemming" (estrazione della radice) e altre analisi del contenuto**
 - Usando regole specifiche della lingua, si convertono le parole nella loro forma base.
 - es., "surfing", "surfed" --> "surf".

Ricerca Booleana in SQL

In realtà c'è un solo tipo di query SQL nell'IR a Ricerca Booleana:

- Select su singola tabella, UNION, INTERSECT, EXCEPT.

`relevance()` è l'ingrediente segreto dei motori di ricerca:

- Combinazioni di statistica, linguistica e trucchi della teoria dei grafi (calcolo della reputazione delle pagine, hub e authority sugli argomenti, ecc.).

- Sfortunatamente, non è facile calcolarla in modo efficiente usando le tipiche implementazioni dei DBMS.

Rilevanza

Quello che ci serve è definire una **funzione di rilevanza** che mi definisce uno **score** dei documenti nella soluzione.

Vogliamo definire come poter **implementare praticamente** tali funzioni, e come poterli approssimare all'atto pratico.

Calcolo della rilevanza

Il calcolo della rilevanza implica quanto spesso i termini di ricerca compaiono nel documento e quanto spesso compaiono nella collezione:

- Più i termini di ricerca vengono trovati in un documento, più questo è rilevante.
- Viene attribuita maggiore importanza al trovare termini *rari* (ovvero, termini di ricerca che sono rari nella collezione, ma che compaiono in questo documento).

Fare questo in modo efficiente negli attuali motori SQL non è facile:

- La "Rilevanza" di un documento rispetto a un termine di ricerca è una funzione che viene chiamata una volta per ogni documento in cui compare il termine (documenti trovati tramite indice invertito):
 - Per un calcolo efficiente, per ogni termine, possiamo memorizzare il numero di volte in cui compare in ogni documento, così come il numero di documenti in cui compare complessivamente.
 - E' necessario anche ordinare i documenti recuperati in base al loro valore di rilevanza.
 - Inoltre, bisogna pensare agli operatori booleani (se la ricerca ha più termini) e a come questi influenzano il calcolo della rilevanza.

Performance

- **DBMS**: in genere garantisce efficienza (generica) su ogni operazione, SELECT, INSERT, UPDATE, DELETE
- **IR**: in genere si fanno solo SELECT, e raramente un INSERT. Per implementare una DELETE, in genere si usa un **flag** delete .

Scalabilità

È importante riuscire a implementare tali motori di ricerca anche in maniera **scalabile**, oltre che efficiente.